UNIVERSIDAD
COMPLUTENSE
MADRID

MÁSTER EN BIG DATA, DATA SCIENCE & BUSINESS ANALYTICS

TRABAJO FIN DE MÁSTER

CURSO 2025-2026

Desarrollo de una aplicación inteligente para una cafetería mediante análisis de mercado y modelización predictiva con Machine Learning (Prophet) para la previsión a 14 días de ingresos (€) y cantidades vendidas en sus tres categorías principales de productos

Ilan Alexander Arvelo Yagua

Anabel Jose Baéz Rodríguez

Genesis Karollay Hernández Gallegos

Luca Iacomino

Marcio Yassuhiro Iha

Fatima Tawfik Vázquez

Madrid, Febrero de 2026

Contenido

1. Introducción. 1
2. Objetivos. 1
   2.1. Objetivo General. 1
   2.2. Objetivos Específicos del Proyecto. 2
3. Comprensión del Negocio. 2
   3.1 Predicción de series temporales en negocio. 2
   3.2. Text Mining y Procesamiento de Lenguaje Natural. 3
4. Comprensión y Preparación de los datos. 3
   4.1 Fuente de datos. 3
   4.2 Preprocesamiento de datos. 4
   4.3. Análisis Exploratorio de Datos (EDA, “exploratory data analysis” en inglés). 5
   4.4. Ingeniería de características (Feature Engineering). 7
5. Modelado. 8
   5.1. Modelo de Predicción de Ingreso Total (Meta Prophet). 8
      5.1.1. Selección de tipo de Modelo: Prophet vs. Modelos Clásicos y Machine Learning. 8
      5.1.2. Métricas de evaluación de modelos predictivos de Ingreso Total. 9
      5.1.3. Modelo - Fase 1 Diseño: entrenamiento 2022-2024, validación todo 2025. 9
      5.1.4. Modelo - Fase 2 Producción: entrenamiento 2022–2025. 12
   5.2. Modelado de Text Mining. 13
      5.2.1. Carga y preprocesamiento. 13
      5.2.2. Extracción de palabras clave con YAKE. 14
      5.2.3. Normalización semántica con Sentence-BERT. 14
      5.2.4. Agregación y cálculo de métricas. 14
      5.2.5. Generación de insights. 14
      5.2.6. Diferencias con el enfoque tradicional (ABSA). 14
6. Evaluación. 15
   6.1. Resultados del Modelo de Predicción. 15
   6.2. Resultados del Text Mining. 16
7. Despliegue Interfaz Streamlit. 17
8. Conclusiones 18
Referencias Bibliográficas 19
ANEXOS 21
   A.Códigos Python en formato html 21
      A.1. Códigos del ETL 21
      A.2. Códigos del EDA 21
      A.3. Códigos de los Modelos de predicción de Ventas y Cantidades 21
      A.4. Códigos del Text Mining y de la Análisis de Sentimiento 22
      A.5. Códigos del Interfaz del Usuario 22

B. Hiperparámetros óptimos seleccionados modelos Prophet. 22
C. Conjuntos de datos y tablas más relevantes 23
D. Documentos 24
E. Videos 24

1. Introducción.

La gestión eficiente de un establecimiento de hostelería exige la capacidad de anticipar la demanda con la mayor precisión posible. En un sector caracterizado por márgenes ajustados y productos perecederos, una estimación incorrecta puede traducirse en desperdicio o en pérdida de oportunidades de venta. Tradicionalmente, las decisiones de compra y planificación se han basado en la experiencia del propietario y en estadísticas descriptivas básicas (medias, máximos y mínimos históricos), un enfoque insuficiente cuando la demanda depende de múltiples factores externos interrelacionados.

El presente Trabajo Fin de Máster aborda esta problemática mediante la aplicación de técnicas de ciencia de datos a un caso real: Café Madrid (nombre anónimo, utilizado como referencia genérica), una cafetería de especialidad ubicada en las inmediaciones del Paseo del Prado de Madrid, en el eje cultural conformado por el Museo del Prado, el Museo Reina Sofía y CaixaForum Madrid[1]. Su localización en una zona de alta afluencia turística expone al negocio a una elevada variabilidad de demanda condicionada por factores como la estacionalidad, los eventos culturales, las condiciones climáticas y el calendario festivo.

El proyecto se articula en dos ejes analíticos complementarios. En primer lugar, se desarrolla un sistema de predicción de ventas diarias basado en el modelo Prophet, que incorpora como variables explicativas las condiciones meteorológicas, los festivos de la Comunidad de Madrid y la afluencia de visitantes al CaixaForum. El sistema genera predicciones con un horizonte de catorce días, alineado con el ciclo de compras del establecimiento. Se construyen cuatro modelos independientes: uno para ingresos totales diarios y tres para las categorías de mayor volumen de ventas: **1)** Cafés Clásicos, **2)** Desayunos, Tostadas y Panes, y **3)** Dulces y Repostería. En segundo lugar, se implementa un modelo de análisis de sentimiento por aspectos aplicado a reseñas de Google Maps, con el objetivo de identificar temas recurrentes, clasificar su polaridad y extraer recomendaciones accionables. Este análisis se complementa con un benchmarking competitivo frente a establecimientos similares de la zona.

Ambos componentes se integran en una interfaz interactiva desarrollada en Streamlit[2], desplegada en la nube. La solución se ha desarrollado íntegramente con herramientas de código abierto (Python, Prophet, TextBlob Loria 2020, Streamlit). La estructura del documento sigue las fases de la metodología CRISP-DM[3], adaptadas al contexto específico del proyecto y al entorno operativo del negocio.

2. Objetivos.

2.1. Objetivo General.

Desarrollar un sistema integral de apoyo a la toma de decisiones para Café Madrid, basado en modelización predictiva de ventas y análisis de reseñas de clientes, con el fin de optimizar la planificación operativa y mejorar la competitividad del negocio.

---

[1] Fundación la Caixa (2024). CaixaForum Madrid - Datos de visitantes. Datos proporcionados directamente por la institución. https://caixaforum.org/es/madrid

[2] Streamlit Inc. (2024). Streamlit: The fastest way to build data apps. https://streamlit.io/

[3] www.datascience-pm.com. Evaluating CRISP-DM for Data Science.

2.2. Objetivos Específicos del Proyecto.

1. Construir modelos predictivos de series temporales para estimar los Ingresos totales (Total revenue) diarios y las unidades vendidas por categoría **1)** “Cafés Clásicos”, **2)** “Desayunos,Tostadas y Panes” y **3)** “Dulces y Repostería”, con un horizonte de predicción de catorce días.

2. Identificar y cuantificar el impacto de factores externos en la evolución de las ventas, incluyendo condiciones climáticas (temperatura y precipitación), calendario festivo de la Comunidad de Madrid y afluencia de visitantes al CaixaForum.

3. Procesar y analizar un corpus de 2.510 reseñas de Google mediante técnicas de procesamiento de lenguaje natural (embeddings semánticos y YAKE, Campos 2020), con el fin de normalizar los elementos clave del servicio, calcular métricas de satisfacción por categorías e identificar tendencias temporales y áreas de mejora estratégica para el negocio.

4. Realizar un benchmarking competitivo mediante el análisis textual de reseñas de establecimientos similares en la zona, identificando oportunidades de diferenciación y posibles líneas de mejora para incrementar la competitividad del negocio.

5. Implementar y desplegar en producción una interfaz interactiva en Streamlit que permita al propietario visualizar predicciones de ventas actualizadas con periodicidad quincenal y consultar los resultados del análisis de reseñas sin necesidad de conocimientos técnicos.

3. Comprensión del Negocio.

3.1 Predicción de series temporales en negocio.

La predicción de la demanda en el sector de la restauración no depende únicamente de los patrones históricos de ventas, sino de un ecosistema de factores externos que actúan como regresores exógenos críticos. La gestión operativa, con horizontes de 7 y 30 días[4] debe considerar las siguientes variables de impacto:

La Estacionalidad y Climatología, con el comportamiento del consumidor está altamente condicionado por el clima. Las temperaturas extremas o las precipitaciones persistentes alteran tanto el volumen de afluencia como el tipo de producto demandado (por ejemplo, preferencia por interiores o terrazas, o bebidas calientes o frías), afectando directamente el inventario de productos perecederos. El Calendario de Festivos y Eventos, puentes, y celebraciones locales rompen la estacionalidad semanal típica. Modificando la demanda esperada. El entorno Turístico y Actividades Culturales en la ubicación del negocio implica que la demanda sea sensible a la agenda de eventos locales, exposiciones o flujos de visitantes estacionales.

Reputación Digital (Google Reviews), en el contexto actual, la percepción online actúa como un motor de atracción. Una fluctuación significativa en la calificación media o un aumento en el volumen de reseñas recientes impactan en la decisión del cliente, pudiendo desplazar la demanda de forma más orgánica pero persistente en el tiempo.

[4]Hyndman, R. J. y Athanasopoulos, G. (2021). Forecasting: Principles and Practice (3rd ed.). OTexts. https://otexts.com/fpp3/

3.2. Text Mining y Procesamiento de Lenguaje Natural.

El análisis de sentimiento, también conocido como *opinion mining*, es un campo del procesamiento de lenguaje natural (NLP) que busca identificar, extraer y cuantificar la actitud subjetiva expresada en textos[5]. En el contexto de la hostelería, las reseñas publicadas por los clientes en plataformas como Google Maps, TripAdvisor o Yelp constituyen una fuente de información no estructurada de alto valor que, tratada mediante técnicas de NLP, permite identificar patrones recurrentes en las opiniones, detectar áreas de mejora y evaluar el posicionamiento competitivo del negocio.

El enfoque adoptado en este proyecto se basa en la extracción automática de elementos mencionados y el cálculo de su satisfacción basada en ratings. A diferencia de enfoques tradicionales que definen categorías predefinidas (café, servicio, ambiente), este sistema descubre automáticamente qué mencionan los clientes y cómo lo valoran.

El pipeline de text mining desarrollado combina tres técnicas complementarias:

1. **YAKE (Yet Another Keyword Extractor)**: Algoritmo no supervisado que extrae palabras clave relevantes de cada oración analizando frecuencia, posición y contexto. No requiere entrenamiento previo y funciona en inglés tras traducción automática de las reseñas.

2. **NLTK Sentence Tokenization:** División de reseñas en oraciones individuales para análisis granular. Esto permite asociar cada elemento mencionado con el contexto específico en el que aparece.

3. **Sentence-BERT (all-MiniLM-L6-v2):** Modelo de embeddings pre entrenado de HuggingFace que genera representaciones vectoriales semánticas de las palabras clave extraídas. Permite agrupar automáticamente elementos similares (ej: "friendly staff", "nice staff", "staff nice") usando similitud coseno con umbral de 0.80 (Reimers 2019).

4. Comprensión y Preparación de los datos.

4.1 Fuente de datos.

Datos de ingreso total y ventas de unidades de productos. La fuente de datos principal del proyecto son los registros de Ingresos totales (Total revenue) diarias del Café Madrid, extraídos del sistema administrativo de contabilidad del establecimiento. Esta base de datos tiene finalidad fiscal, ya que consolida los ingresos reportados a la administración, por lo que no existen facturas separadas por tipo de pago. El dataset original consta de 990.176 registros a nivel combinado entre línea de producto y factura, correspondientes al periodo comprendido entre enero de 2019 y diciembre de 2025. Cada registro contiene 12 variables que incluyen el número de factura, el tipo de factura (T ticket venta, TD ticket de devolución, F para factura), la fecha de la transacción, la ubicación dentro del local, el importe total, el método de pago, el producto vendido, la cantidad y el precio unitario.

Datos climatológicos. Se obtuvieron de la Agencia Estatal de Meteorología (AEMET)[6], incluyendo temperatura media, máxima y mínima diarias, así como precipitación acumulada diaria, para la estación meteorológica de Madrid Retiro, la más próxima al establecimiento.

[5]Liu, B. (2012). Sentiment Analysis and Opinion Mining. Synthesis Lectures on Human Language Technologies, Morgan & Claypool.

[6]AEMET - Agencia Estatal de Meteorología (2025). Datos climatológicos históricos. https://www.aemet.es/

No obstante, la estación de Madrid Retiro no disponía de registros para el periodo comprendido entre el 29/09/2025 y el 31/12/2025, por lo que, para garantizar la continuidad de la serie y evitar valores faltantes en el tramo final del análisis, se utilizaron los datos correspondientes a la estación meteorológica del Aeropuerto de Madrid, que sí contaba con información completa para esas fechas.

Calendario festivo. Se construyó un calendario que incluye los festivos nacionales, autonómicos de la Comunidad de Madrid y locales del municipio de Madrid para el periodo 2022-2026. En lugar de codificarse como una única variable binaria, la variable festivo se transformó en variables dummy independientes para cada festividad (por ejemplo, *festivo_almudena*, *festivo_ano_nuevo*, *festivo_asuncion_de_la_virgen*), dado que no todos los festivos tienen el mismo impacto en los Ingresos totales (Total revenue) de la cafetería. Adicionalmente, se incorporó como festivo el evento del Pride correspondiente al día de la marcha, ya que el recorrido transcurre directamente por las inmediaciones del establecimiento y genera un efecto significativo en la afluencia y la demanda.

Afluencia al CaixaForum. Se obtuvieron los datos de visitantes diarios al centro cultural CaixaForum, proporcionados directamente por la Fundación la Caixa, para el periodo 2022-2025. Esta variable se incorpora como regresor externo dada la hipótesis de negocio de que la afluencia de visitantes a esta institución adyacente al establecimiento genera un efecto de arrastre sobre la demanda de la cafetería.

Datos para el análisis de reseñas (Text Mining). Para el desarrollo del componente de text mining, se recopilaron dos conjuntos de datos diferenciados. En primer lugar, se extrajo la totalidad de las reseñas históricas del perfil de Google Maps del Café Madrid, obteniendo un registro inicial de 2.510 opiniones publicadas entre septiembre de 2014 y noviembre de 2025. Tras un proceso de limpieza para descartar registros sin texto o nulos (877 casos), se consolidó una muestra final de 1.633 reseñas válidas, las cuales presentan una valoración promedio de 4.35 sobre 5.0.

En segundo lugar, se obtuvieron aproximadamente 5971 reseñas de establecimientos competidores de la zona mediante técnicas de *scraping* automatizado con SerpAPI. En este caso, se filtraron únicamente aquellas opiniones con una valoración de 4 estrellas o superior, con el objetivo de centrar el análisis en las fortalezas y ventajas competitivas percibidas por los clientes en el entorno local.

Ambos conjuntos de datos fueron estructurados en campos clave como la fecha de publicación, el rating y el comentario original. Finalmente, todos los textos se tradujeron automáticamente al inglés para su procesamiento analítico, ya que los modelos de procesamiento de lenguaje natural (NLP) utilizados ofrecen una mayor precisión y consistencia en este idioma

4.2 Preprocesamiento de datos.

Preprocesamiento de datos para la predicción de Ingreso total y ventas por categorías. El proceso de limpieza y transformación de los datos de Ingresos totales (Total revenue) se ejecutó en varias fases. En primer lugar, se eliminaron los tickets de devolución (tipo TD) y sus facturas asociadas, excluyendo 751 registros relacionados con devoluciones. Se filtraron los registros con importes inusuales superiores a 100 € por factura, el percentil 99.99% de la distribución histórica de total de facturas tiene un valor de 96.73 €, lo cual

significa que menos de 1 en 10.000 facturas serán mayores a 96.73 €, por esto se tomó esta decisión.

Posteriormente, los 322 productos únicos identificados en el catálogo se clasificaron manualmente en 17 categorías de producto, con apoyo del menú del negocio para garantizar la coherencia comercial de la agrupación. Las categorías resultantes incluyen: Cafés Clásicos, Cafés con Alcohol, Cafés con Personalidad, Desayunos Tostadas y Panes, Dulces y Repostería, Bebidas Sin Alcohol, Bebidas Con Alcohol, Cervezas, Infusiones y Tés, Frappes y Smoothies, Zumos, Crema, Ensaladas, Pastas y Arroces, Pinchos y Raciones, Suplementos y Take Away. Los productos no asignables a ninguna categoría se etiquetaron como “no modelar ”y fueron excluidos del análisis.

El periodo 2019-2021 fue descartado del análisis por su falta de representatividad, dado el impacto disruptivo de la pandemia de COVID-19 en los patrones de consumo del sector hostelero (Figura 1). La ventana temporal seleccionada comprende desde el 1 de enero de 2022 hasta el 31 de diciembre de 2025. Los datos se agregaron a nivel diario, generando para cada fecha el Ingreso total (Total revenue), el número de facturas y las unidades vendidas por categoría. Este dataset diario se enriqueció con las variables externas (clima, calendario festivo y CaixaForum) mediante operaciones de unión por fecha. El dataset final para modelado con totales diarios contiene 1.444 observaciones con 26 variables.

Preprocesamiento de datos para el análisis de reseñas. El preprocesamiento de los datos se ejecutó a través de una secuencia de múltiples etapas, diseñadas específicamente para preservar la integridad estructural de la información. El proceso inició con la Etapa 1, dedicada a la conversión de ratings, donde los formatos de texto originales como "FIVE" o "FOUR" se transformaron en valores numéricos del 1 al 5, tomando simultáneamente el campo review clean como la fuente principal del texto traducido. Posteriormente, en la Etapa 2, se procedió a la eliminación de valores nulos, filtrando todas aquellas reseñas que carecían de contenido textual. Esta acción resultó en una reducción de la muestra, pasando de 2.510 a 1.633 reseñas válidas para el análisis.

La Etapa 3 consistió en la división en oraciones, un paso crítico que se realizó antes de cualquier limpieza profunda mediante el uso de la herramienta nltk.sent_tokenize. Se decidió mantener la puntuación intacta en este punto para facilitar la segmentación precisa, limitándose únicamente a eliminar los marcadores de plataforma como "(Translated by Google)" y "(Original)". Una vez segmentado el texto, se dio paso a la Etapa 4 de limpieza de texto, donde se aplicó la conversión a minúsculas, la normalización de espacios y la eliminación total de caracteres especiales y puntuación mediante la expresión regular [^a-z0-9\s]. Finalmente, en la Etapa 5, se realizó la extracción de keywords aplicando el algoritmo YAKE sobre cada oración limpia, configurado para n-gramas de hasta tres palabras y un límite de diez términos por segmento. Como resultado final, este pipeline procesó las 1.633 reseñas para generar un total de 22.629 menciones de elementos extraídos.

4.3. Análisis Exploratorio de Datos (EDA, “exploratory data analysis” en inglés).

EDA de datos de Ingreso total (Total revenue) y ventas de categorías. El análisis exploratorio reveló varios hallazgos relevantes para el diseño del modelo. La serie temporal del Ingreso total (Total revenue) diario (Figura 1) muestra una tendencia creciente a lo largo del periodo analizado, con una media de aproximadamente 1.500 € diarios que se incrementa progresivamente hasta superar los 2.000 € en los últimos meses de 2025.

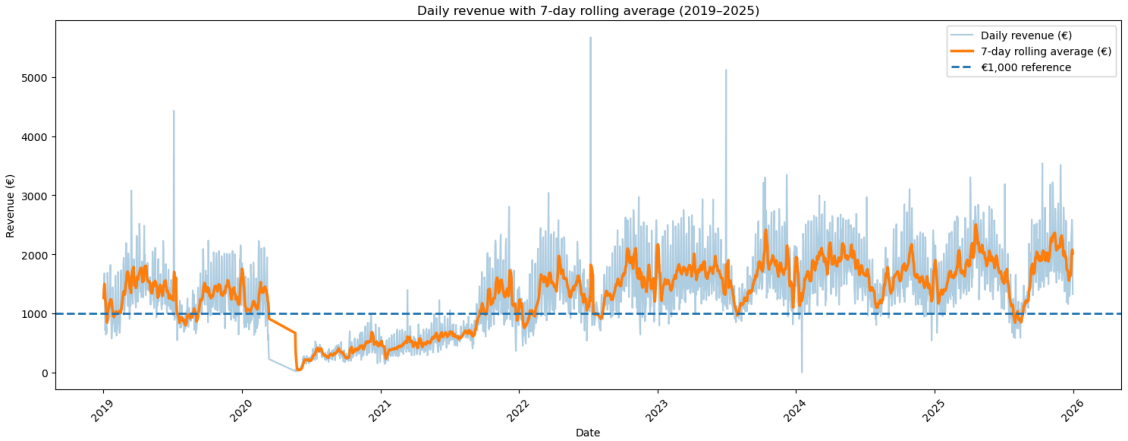

Figura 1. *Evolución de Ingresos totales diarios (Daily revenue) y su media móvil de 7 días, con línea de referencia en €1.000 (2019–2025).*

El análisis de las ventas de categorías de producto permitió identificar que tres de ellas concentran la mayor parte del volumen de ventas en unidades: Las medias diarias fueron aproximadamente 192 unidades para Cafés Clásicos, 85 para Dulces y Repostería y 84 para Desayunos, tostadas y panes. Las restantes categorías presentan volúmenes significativamente menores, con medias diarias frecuentemente inferiores a 30 unidades, lo que introduce un alto nivel de ruido y dificulta la obtención de predicciones fiables. Esta observación motivó la decisión de centrar el modelado predictivo en estas tres categorías principales, además del Ingreso total (Total revenue).

Al momento del análisis de los datos se aplicó un truncamiento (clipping) estableciendo un límite superior en los Ingresos totales (Total revenue) a 3,500 €, Cafés Clásicos 350 unidades, Dulces y Repostería 350 unidades, Desayunos, tostadas y panes 300 unidades, con el objetivo de mitigar el efecto de eventos extremadamente inusuales que actúan como ruido estadístico. Esto ayuda a que al crear un modelo de predicción este se enfoque en la tendencia general y no en "picos" imposibles de predecir que podrían sesgar los parámetros del algoritmo.

Estacionalidad de los datos. El siguiente gráfico (Figura 2) muestra el patrón promedio de Ingresos totales (Total revenue) diarias de los últimos 4 años (2022-2025), y evidencia un patrón estacional anual claramente definido. Se observa un ciclo recurrente caracterizado por un descenso significativo durante los meses de verano (julio–agosto) y un incremento progresivo que culmina en un máximo durante el otoño (octubre–noviembre). La consistencia del patrón a lo largo de cuatro años, junto con la estabilidad del rango intercuartílico, confirman la presencia de un componente estacional estructural en la serie temporal.

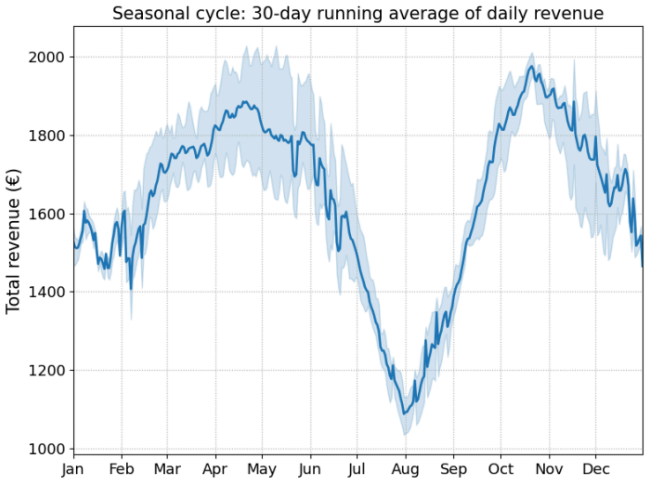

Figura 2. *Patrón estacional anual, ingreso total promedio, con media móvil de 30 días y rango intercuartílico (25% a 75% de observaciones en la misma fecha del año).*

EDA de datos de reseñas. El análisis se basa en un conjunto final de 1.633 reseñas válidas, tras filtrar las entradas nulas de una muestra inicial de 2.510. Los datos muestran una distribución de frecuencias fuertemente asimétrica con una clara inclinación hacia las valoraciones positivas. De hecho, existe una predominancia absoluta de la puntuación máxima: las 5 estrellas acumulan 1.092 reseñas, lo que representa el 66,9% del total.

Sin embargo, al observar la evolución temporal (Figura 3), se detecta un descenso progresivo en la satisfacción. Aunque el periodo alcanzó un pico de 4.94 en febrero de 2025, el promedio global ha ido bajando hasta situarse en 4.34. Esta tendencia se confirma al comparar ambos semestres: la nota media cayó de 4.52 a 4.13, tocando fondo en noviembre con un promedio de 3.0. Estos resultados reflejan un deterioro real en la percepción del servicio que contrasta con la alta acumulación histórica de reseñas positivas.

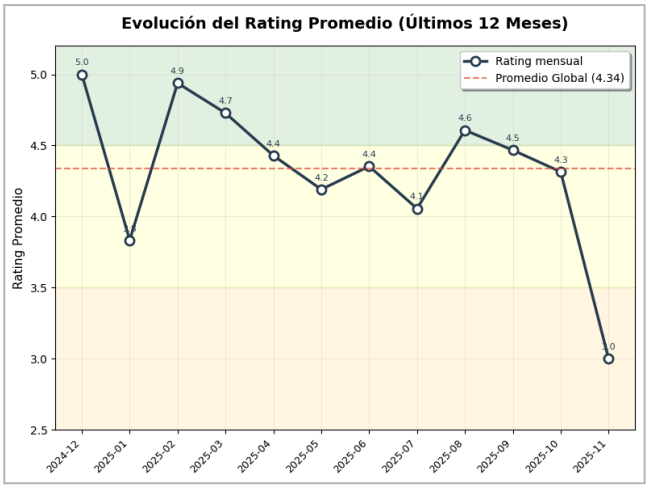

Figura 3. *Evolución del Rating Promedio en los últimos 12 meses*

4.4. Ingeniería de características (Feature Engineering).

Feature engineering para la predicción de Ingreso Total y ventas de categorías. A partir de las variables originales y externas se derivaron los siguientes regresores:

Variables temporales: día de la semana (0-6), indicador de fin de semana, número de semana del año, día del mes, mes y año. Estas variables fueron utilizadas en los modelos lineal y XGBoost para comparar su rendimiento con el modelo elegido que fue el Prophet. El Prophet internamente incluye el efecto de estas variables en sus cálculos de efectos estacionales. Se creó también la variable “festivos”, la cual es una variable categórica que contiene 16 niveles, comprendidos por 15 festivos de la comunidad de Madrid, más 1 nivel de referencia llamado “no_festivo” para los días regulares; esta variable se convirtió en dummies al momento de evaluar los modelos lineales.

Variables climáticas derivadas: rango de temperatura diario (tmax - tmin), indicador binario de día caluroso (tmed ≥ 30°C), indicador binario de día frío (tmed ≤ 6°C), indicador de lluvia (precipitación ≥ 1 mm) e indicador de lluvia intensa (precipitación ≥ 5 mm).

Variables de retardo (lag): se incorporaron los valores del revenue y del número de facturas con un retardo de 14 días (revenue_lag_14 e invoices_lag_14), con el objetivo de capturar el efecto de la actividad reciente del negocio como predictor de la demanda futura. La elección del retraso de 14 días se alinea con el horizonte de predicción del modelo.

Feature engineering para el análisis de texto.

Extracción automática de elementos. En contraste con los métodos tradicionales que se basan en categorías fijas, este sistema emplea el algoritmo YAKE para identificar

automáticamente los temas que surgen de forma espontánea en las opiniones de los clientes. El proceso estructura la información de cada reseña extrayendo el identificador del local, el concepto clave mencionado (por ejemplo, "friendly staff" o "good coffee"), la frase original para no perder el contexto semántico y la valoración numérica del 1 al 5. A nivel cuantitativo, el rendimiento de esta extracción fue notable, obteniendo un total de 22.629 menciones. Aunque inicialmente se detectaron 8.769 elementos únicos, la posterior etapa de normalización permitió consolidar esta información en 5.522 términos finales, logrando así una reducción del 37% que optimiza significativamente el conjunto de datos para su análisis

Normalización semántica de elementos. Para optimizar la consistencia de los datos y reducir su dimensionalidad, se implementó una normalización semántica basada en *embeddings* del modelo *all-MiniLM-L6-v2.* El procedimiento técnico siguió una secuencia lógica de cuatro pasos: primero, se transformaron los 8.769 ítems únicos originales en vectores; a continuación, se calculó la similitud del coseno entre ellos para medir su afinidad semántica y se agruparon aquellos que superan un umbral de coincidencia del 0.80. Finalmente, se seleccionó el ítem más frecuente dentro de cada clúster para que actuara como la forma canónica representativa del grupo.

Esta estrategia resultó fundamental para gestionar la variabilidad del lenguaje natural, logrando unificar bajo una misma etiqueta expresiones equivalentes. Por ejemplo, variantes como "friendly staff" o "nice staff" se consolidaron en "friendly nice", y distintas referencias al desayuno se agruparon correctamente. Gracias a esto, se reduce drásticamente el ruido textual y se consigue que menciones con diferentes palabras, pero idéntico significado, cuenten cómo un mismo concepto en el análisis.

Features agregados. Tras completar la normalización, el sistema consolida la información para generar el perfil analítico de cada término. Se calculan métricas fundamentales como el nombre estandarizado del elemento, su frecuencia total de aparición en el conjunto de reseñas y el rating promedio obtenido únicamente de las opiniones que lo mencionan. Basándose en este promedio, se crea una clasificación automática del sentimiento en cuatro niveles: se consideran "Muy Positivos" los elementos con una puntuación igual o superior a 4.5, y "Positivos" los que oscilan entre 3.5 y 4.5. Por su parte, el intervalo de 2.5 a 3.5 se define como "Neutro", mientras que la categoría de "Negativo" se asigna a cualquier elemento cuyo promedio quede por debajo de 2.5.

5. Modelado.

5.1. Modelo de Predicción de Ingreso Total (Meta Prophet).

5.1.1. Selección de tipo de Modelo: Prophet vs. Modelos Clásicos y Machine Learning.

Durante la fase exploratoria se evaluaron tres aproximaciones metodológicas para determinar la más idónea para el negocio: **1)**Modelos Clásicos (ARIMA/SARIMA), se analizaron como punto de partida, pero se descartaron por su dificultad para incorporar variables exógenas (clima, eventos) de forma sencilla. Estos modelos asumen relaciones lineales que no siempre reflejan la realidad comercial y son altamente sensibles a valores atípicos, exigiendo un preprocesamiento de anomalías muy exhaustivo. **2)**Modelos de Aprendizaje Automático (Regresión Lineal y XGBoost), la Regresión Lineal sirvió como línea

base (baseline) para cuantificar el rendimiento mínimo esperable. Por su parte, XGBoost, aunque capaz de capturar relaciones no lineales complejas, presentó métricas consistentemente inferiores en predicciones a horizontes largos (un año completo). Ambos modelos requieren una ingeniería de características manual significativamente compleja (creación de retardos, estadísticas móviles y codificaciones estacionales) y suelen ser menos interpretables en entornos empresariales. **3)**Prophet (desarrollado por el equipo de *Core Data Science* de Meta, Taylor y Letham, 2018[7]), Seleccionado como el modelo final. A diferencia de los anteriores, Prophet implementa un modelo mixto aditivo y multiplicativo que descompone la serie en componentes interpretables: tendencia con detección automática de puntos de cambio (changepoints), estacionalidades múltiples (semanal y anual) y efectos de festivos configurables. A diferencia de los modelos ARIMA tradicionales, Prophet permite integrar variables como temperatura, precipitación o afluencia de visitantes sin necesidad de transformaciones complejas, y presenta una mayor robustez frente a valores faltantes y *outliers*, habituales en datos operativos reales[8].

5.1.2. Métricas de evaluación de modelos predictivos de Ingreso Total.

Para evaluar el rendimiento de los modelos de series temporales a lo largo de las distintas fases de validación se emplean cuatro métricas complementarias, seleccionadas por su interpretabilidad en contextos de negocio. El error absoluto promedio "**MAE"** (en inglés "Mean Absolute Error") mide el error en las mismas unidades que la variable objetivo (euros para Ingresos totales, ventas de unidades por categorías), siendo la métrica más intuitiva para el propietario ya que indica directamente cuánto se desvía la predicción de la realidad en promedio. El error cuadrático medio "**RMSE"** (en inglés "Root Mean Squared Error") penaliza de forma cuadrática los errores grandes, lo que resulta útil para detectar predicciones con desviaciones importantes en días puntuales como festivos o eventos inesperados. El error absoluto promedio porcentual "**MAPE"** (en inglés "Mean Absolute Percentage Error") expresa el error como porcentaje de los valores reales, facilitando la comparación entre modelos con escalas diferentes (euros vs. unidades) y constituyendo la métrica principal de referencia al ser la más empleada en la industria para pronósticos de demanda. Finalmente, el percentil 95 del error absoluto (**P95** AbsError) cuantifica el peor escenario razonable, indicando el error máximo que se espera en el 95% de los días.

5.1.3. Modelo - Fase 1 Diseño: entrenamiento 2022-2024, validación todo 2025.

El proceso de diseño de los modelos incluyó la selección del tipo modelo basado en las métricas optimizadas mediante un proceso iterativo de selección de variables y de parámetros de entrenamiento, lo cual incluyó una evaluación para garantizar la estabilidad del modelo y que no presente sesgos estacionales.

Entrenamiento. En una primera etapa, cada uno de los cuatro modelos se entrenó con datos entre enero 2022 hasta diciembre 2024, y se evaluó sobre un año completo como validación entre enero 2025 hasta diciembre 2025 (Tabla 1). Este diseño de validación asegura que el modelo se enfrenta a todas las estacionalidades del ciclo anual incluyendo los meses de verano de baja demanda, los picos de otoño y todos los periodos festivos.

---

[7]Taylor, S. J. y Letham, B. (2018). Forecasting at Scale. The American Statistician, 72(1), 37-45. https://doi.org/10.1080/00031305.2017.1380080

[8]Documentación oficial de Prophet: https://facebook.github.io/prophet/

La siguiente tabla compara los resultados del modelo Prophet frente a otros modelos en el conjunto de validación del año 2025, se generó un modelo para cada variable utilizando las mismas variables de entrenamiento:

Variable	Modelo	MAE	RMSE	MAPE%	P95
Ingreso Total (Total revenue) (€)	Prophet	189,6	246,5	11,5	503
	Linear Regression	226.0	290.2	14.7	567
	XGBoost	275.1	341.6	17.1	637
Cafés Clásicos (unidades)	Prophet	29,7	36,5	16,2	68
	Linear Regression	27,7	36,0	14,2	70
	XGBoost	29,9	38,3	15,7	71
Desayunos, tostadas y panes (unidades)	Prophet	14,1	17,5	18,6	32
	Linear Regression	17,0	21,1	24,7	43
	XGBoost	16,5	20,4	23,5	39
Dulces y Repostería (unidades)	Prophet	11,9	15,0	16,7	28
	Linear Regression	13,0	16,6	18,6	32
	XGBoost	14,5	18,8	21,2	37

Tabla 1. *Prophet vs. Linear Regression, XGBoost — Test set 2025 (un año completo).*

Prophet demuestra una precisión superior frente a los modelos de Machine Learning tradicionales en tres de las cuatro variables analizadas. En cuanto al Ingreso total (Total revenue), Prophet lidera con un MAPE del 11,5% y un MAE de 189,6 €, cifras que garantizan una operatividad financiera sólida. En Desayunos,tostadas y panes, Prophet logra un MAPE del 18,6%, superando significativamente el 24,7% de la Regresión Lineal y el 23,5% de XGBoost. En Dulces y Repostería, el modelo mejora en 4,5 puntos porcentuales de MAPE respecto a XGBoost (16,7% vs. 21,2%) y reduce el error en el percentil 95 de 37 a 28 unidades. Únicamente en Cafés Clásicos la Regresión Lineal obtiene un MAPE ligeramente inferior a Prophet (14,2% vs. 16,2%), aunque con un MAE y RMSE prácticamente equivalentes (27,7 vs. 29,7 y 36,0 vs. 36,5), lo que indica una ventaja marginal del modelo lineal en esta variable específica. Por estos motivos se consolidó Prophet como el modelo seleccionado.

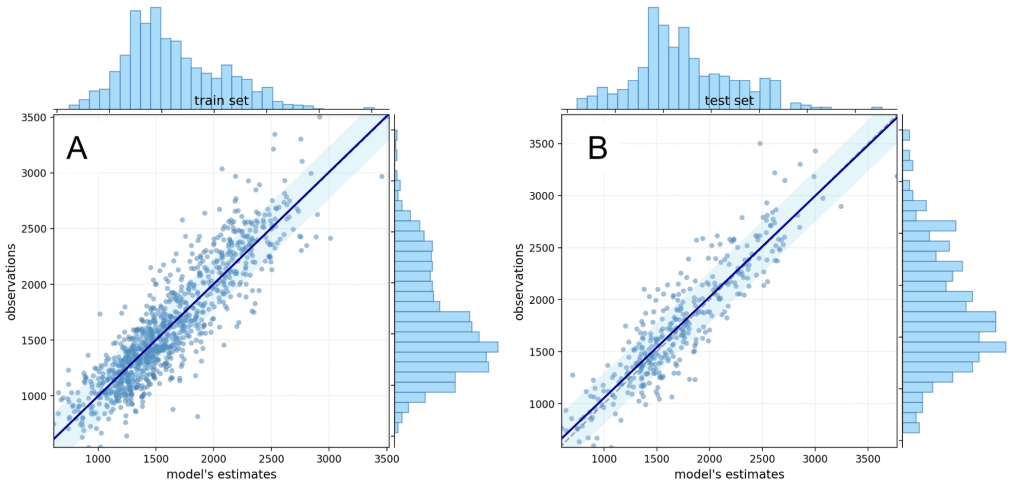

Figura 4. *Modelo Prophet de Ingreso total €: Relación Predicciones y Observaciones reales, línea sólida regresión lineal, banda transparente es 1 desviación estándar de la regresión. Figura 4A) Datos de entrenamiento 2022-2024, Figura 4B) Datos de validación 2025.*

Evaluación de calidad del modelo. La gráfica de dispersión de valores predichos contra valores observados (Figura 4) que se muestra a continuación nos indica que el modelo no tiene sesgo para un rango de magnitud de los valores de ventas, y que la relación promedio entre predicciones y valores observados es de 1 a 1. En la gráfica de estabilidad del modelo (Figura 5), que presenta un gráfico de barras con el MAE agrupado por mes, se puede observar en general que la mayoría de los meses tiene un MAE con rango entre 150-225 €, y que excepcionalmente en febrero 2025 el MAE es de menos de 150 €, y el mes más difícil de predecir es septiembre 2025 con un MAE mayor a 250 €.

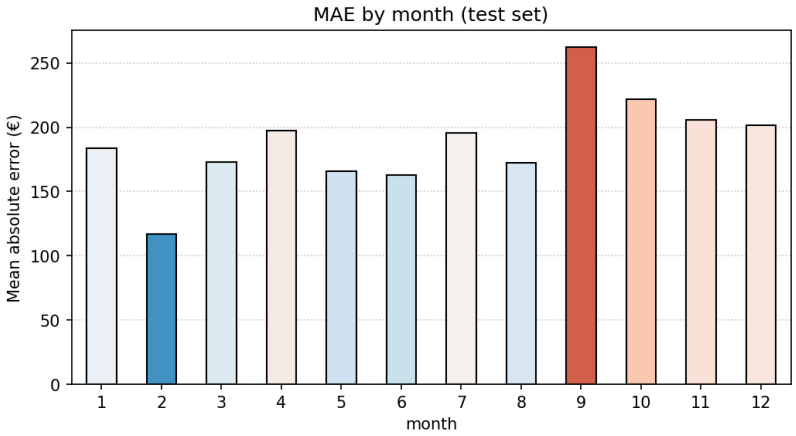

Figura 5. *Estabilidad del modelo Prophet de Ingreso total en diferentes meses del año 2025, MAE promedio por meses del año.*

Efecto de las variables principales. Del modelo Prophet se obtuvo una descomposición de los efectos de las variables temporales (Figura 6). Se observa una tendencia general positiva de incremento de ingresos totales promedio, que en los días de la semana Sábado y Domingo se espera un incremento promedio de ingresos totales de alrededor de 20% y 25% aproximadamente, que entre Mayo y Junio se espera que los ingresos totales incrementen entre 20-25%, y que los ingresos caigan en agosto 25%. En cuanto a los festivos, la mayoría generan efectos entre -25% y +50% sobre el nivel base, destacando un pico excepcional para el evento de Pride Madrid con un estimado de incremento de los ingresos totales mayor al 100% sobre la tendencia promedio (esto se interpreta como duplicar el ingreso total).

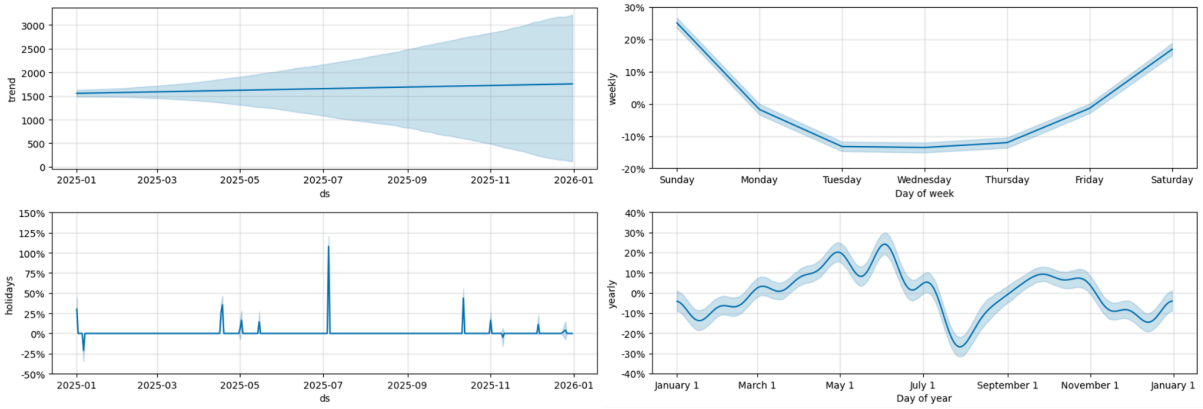

Figura 6. *Efectos temporales y de festivos en modelo Prophet de Ingreso total, datos de entrenamiento 2022-2024 y datos de validación 2025.*

Efecto de los regresores adicionales. Los efectos de variables adicionales en la tendencia general de ingresos totales son presentados en la siguiente (Figura 7) Las variables de clima fueron utilizadas con efectos multiplicativos, siendo la más importante la temperatura media (tmed), la cual puede modificar los ingresos totales promedio en +/- 6%, la variable del rango de temperatura (temp_range) en el día tiene un efecto de +/- 1%; respecto a temperaturas extremas, los días calurosos (is_hot) tienen un efecto poco significativo con posible incremento de +0.07% de los ingresos totales, sin embargo los días fríos (is_cold) tienen un significativo efecto negativo de -3.5% del ingreso total promedio. La variable de retardo en el conteo de facturas 14 días atrás (invoices_lag_14) fue utilizada de forma aditiva, y puede ajustar el promedio esperado de ingreso total en +/- 100 € en la mayoría de los casos. La variable de visitantes al Caixaforum tiene un efecto multiplicativo de entre -20% y +40% del ingreso total promedio, por lo cual es la variable de regresores adicionales más importante, su interpretación es que ella representa un indicador indirecto de afluencia general a eventos culturales en la zona, y no directamente que solo sus visitantes son la clientela del café.

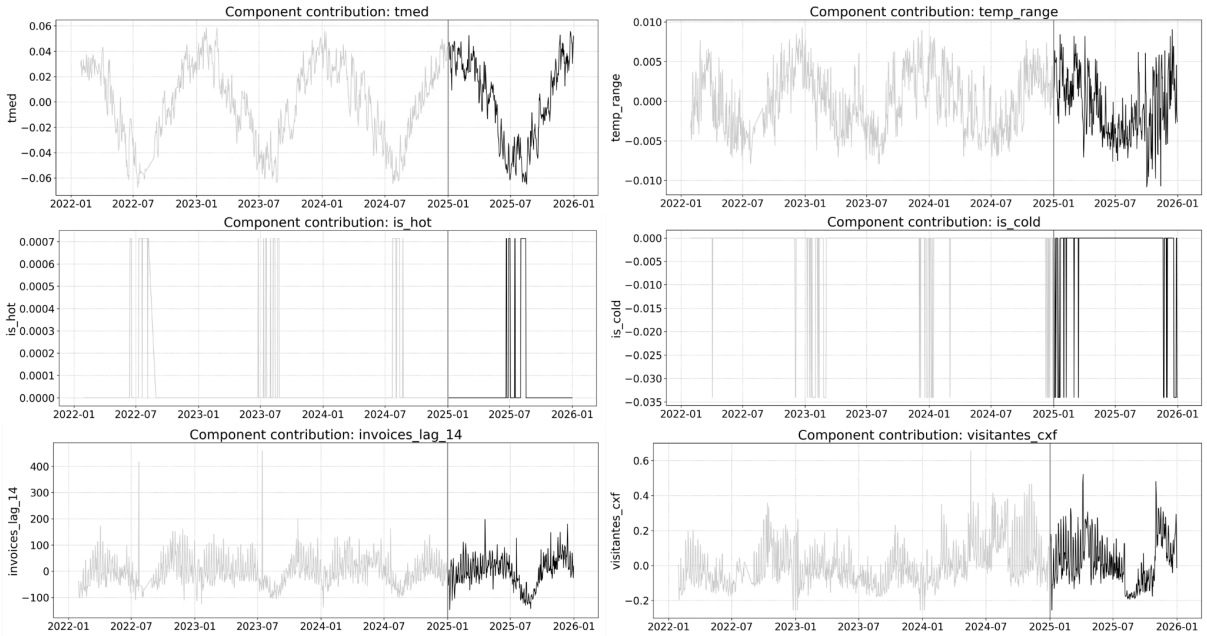

Figura 7. *Efectos de variables adicionales en el modelo Prophet de Ingreso total, datos de entrenamiento 2022-2024 y datos de validación 2025.*

Selección de Variables. De manera iterativa, se evaluó si las variables tenían un impacto en las métricas de los modelos presentados en la tabla 2. Las siguientes variables fueron excluidas al no tener un impacto significativo en el modelo de Prophet: precipitaciones, retardos directos de los Ingresos totales y ventas de unidades, temperatura máxima y mínima. Aunque estas variables tienen un efecto, podrían estar correlacionados con la estacionalidad y por ello individualmente no tuvieron un efecto mayor en el desempeño del modelo.

5.1.4. Modelo - Fase 2 Producción: entrenamiento 2022–2025.

Una vez validado el rendimiento de Prophet en el año completo de prueba (2025) en la fase anterior, se re-entrenaron los cuatro modelos utilizando todos los datos disponibles (enero

2022 – diciembre 2025) con los parámetros óptimos y las variables seleccionadas, con el fin de incorporar la máxima información histórica disponible.

Las métricas del modelo entrenado con los datos 2022-2025 fueron similares a las obtenidas en la fase de diseño del modelo.

Variable	n	MAE	RMSE	MAPE %	AbsError P95
Ingresos totales diarios (€)	1416	176.82	227.78	11.74	454.17
Cafés Clásicos (uds.)	1416	20.63	26.42	11.50	52.35
Desayunos, tostadas y panes (uds.)	1416	12.89	16.33	16.77	30.78
Dulces y Repostería (uds.)	1416	11.51	14.81	14.92	29.47

Tabla 2. *Métricas de entrenamiento de los modelos de producción Prophet, utilizando todos los datos históricos 2022-2025.*

Las métricas obtenidas en el entrenamiento del modelo de producción son similares a las métricas de la validación de la fase de diseño. Si bien las métricas son en magnitud comparables (Tabla 1, Tabla 2), se debe tener precaución en su interpretación, ya que la tabla anterior son métricas con valores de entrenamiento, o en otras palabras, las predicciones del modelo sobre valores conocidos con los que ha entrenado (todos los disponibles, 2022-2025). El verdadero desempeño del modelo se evaluará con su capacidad de predecir valores no observados en la fase de producción.

Después de validar que los modelos para producción eran satisfactorios entrenando con todos los datos 2022-2025, cada modelo se almacenó como un model_bundle que incluye el modelo Prophet ajustado, la lista de regresores esperados en tiempo de predicción, y un diccionario de metadatos con la fecha de creación, el horizonte de predicción (14 días), estrategias de imputación y las versiones de las bibliotecas clave (scikit-learn, Prophet, pandas). Esta estructura garantiza la trazabilidad y reproducibilidad de cada modelo desplegado en producción.

5.2. Modelado de Text Mining.

La solución tecnológica implementada se estructura bajo una arquitectura de pipeline secuencial compuesta por cinco etapas críticas que transforman los datos brutos en conocimiento accionable. El flujo de información comienza con la (1) ingesta de las reseñas en formato CSV, seguido de una fase de preprocesamiento y limpieza, para luego avanzar hacia la (2) extracción de características mediante YAKE. Posteriormente, se ejecuta una (3) normalización semántica utilizando embeddings vectoriales, finalizando con la (4) agregación estadística de los datos y la (5) generación de insights estratégicos.

5.2.1. Carga y preprocesamiento.

El proceso inicia con la carga de un archivo base que contiene 2.510 reseñas originales. En esta fase preliminar, se ejecutan rutinas de limpieza esenciales para garantizar la calidad del análisis posterior. Estas operaciones incluyen la conversión estandarizada de las calificaciones textuales a valores numéricos, transformando etiquetas como "ONE" o "FIVE" en sus equivalentes 1 y 5 respectivamente, así como la eliminación de registros nulos o vacíos. Adicionalmente, se realiza una segmentación del texto en oraciones individuales preservando la puntuación original, seguida de una limpieza que unifica el texto a minúsculas y elimina caracteres especiales irrelevantes. Como resultado de este filtrado

riguroso, se obtuvo un subconjunto depurado de 1.633 reseñas válidas listas para el procesamiento algorítmico.

5.2.2. Extracción de palabras clave con YAKE.

Para la identificación de los temas relevantes, el sistema emplea el algoritmo YAKE (Yet Another Keyword Extractor), una herramienta no supervisada que destaca por su independencia de corpus de entrenamiento y su eficacia multilingüe. La configuración del algoritmo se ajustó para procesar texto en inglés, permitiendo la identificación de n-gramas de hasta tres palabras. Para cada oración procesada, el sistema extrae las 10 palabras clave más relevantes, aplicando un umbral de deduplicación de 0.9 para evitar redundancias. Esta metodología, que considera factores como la frecuencia, la posición y la coaparición de términos, permitió extraer un total de 22.629 menciones específicas, asociando cada una de ellas al rating global de la reseña correspondiente.

5.2.3. Normalización semántica con Sentence-BERT.

Dada la variabilidad natural del lenguaje, se integró una etapa de normalización semántica utilizando el modelo all-MiniLM-L6-v2 de HuggingFace Sentence Transformers. Este modelo, seleccionado por su balance óptimo entre velocidad y precisión, genera embeddings de 384 dimensiones que capturan el significado profundo de las frases. El algoritmo de clustering diseñado calcula la similitud coseno entre los vectores de las frases extraídas; si la similitud entre dos elementos supera el umbral del 0.80, es decir, un 80% de equivalencia semántica, estos se agrupan bajo un mismo clúster. Este proceso demostró una alta eficiencia al reducir los 8.769 elementos únicos iniciales a 5.522 formas canónicas normalizadas, logrando una compresión del espacio de características del 37% sin pérdida de información relevante.

5.2.4. Agregación y cálculo de métricas.

Una vez normalizados los elementos, el sistema procede a la agregación estadística para construir métricas interpretables. Para cada elemento canónico, se calcula la frecuencia absoluta de menciones y el promedio aritmético de los ratings de las reseñas donde aparece. Estos valores permiten asignar una categoría cualitativa de sentimiento al elemento. Para garantizar la robustez estadística de los resultados, se aplica un filtro de significancia que descarta aquellos elementos con menos de 5 menciones, considerándolos ruido estadístico y centrando el análisis únicamente en los temas recurrentes y representativos para la experiencia del cliente.

5.2.5. Generación de insights.

La fase final del modelado se centra en la interpretación estratégica de los datos agregados. El sistema clasifica automáticamente los hallazgos en dos categorías principales: "Fortalezas", definidas como aquellos elementos con un rating promedio igual o superior a 4.0 y un volumen significativo de menciones, y "Áreas de mejora", que incluyen elementos con ratings inferiores a 3.5. Paralelamente, se ejecuta un análisis temporal que agrupa las reseñas por mes para calcular promedios mensuales y comparar el rendimiento de los últimos seis meses frente al semestre anterior, facilitando así la detección temprana de tendencias positivas o negativas en la percepción del servicio.

5.2.6. Diferencias con el enfoque tradicional (ABSA).

Es fundamental destacar que este sistema difiere sustancialmente de los métodos clásicos de Análisis de Sentimiento Basado en Aspectos (ABSA). Mientras que el ABSA tradicional depende de categorías predefinidas y diccionarios estáticos (como "comida" o "servicio"), el modelo implementado descubre automáticamente los temas de conversación, ofreciendo una mayor flexibilidad ante cambios en el negocio y eliminando la necesidad de configuración manual. Aunque presenta limitaciones, como la asignación del rating global de la reseña al elemento específico en lugar de calcular una polaridad por oración, este enfoque ofrece la ventaja de generar métricas directamente interpretables en una escala de 1 a 5, simplificando la toma de decisiones basada en datos.

6. Evaluación.

6.1. Resultados del Modelo de Predicción.

Los modelos de producción entrenados con datos del 2022 al 2025 se utilizaron para predecir Enero del 2026, en modo producción bajo supervisión, para confirmar que el desempeño del mismo se sostiene con nuevos valores no observados previamente.

Entradas del modelo y técnicas de imputación. Para generar las predicciones, el modelo necesita que se le suministre el periodo de fechas requeridas, y para dichas fechas, la información climática, los valores de personas que atienden al Caixaforum, y los retardos del conteo del número de facturas 14 días previos a la fecha a predecir. Para la creación del horizonte de predicción hemos realizado una interfaz de usuario en Streamlit (explicada en mayor detalle en la siguiente sección), en la misma se suministra un documento con el registro de ingresos totales (Total revenue) que contenga por lo menos los últimos 14 días del Cafe Madrid, de allí se generarán las fechas futuras a predecir a partir de la última fecha registrada. Los datos del clima son todos imputados mediante los valores promedios históricos para cada día del año, los valores de retardos de conteo de facturas a 14 días previos son valores reales obtenidos del documento de registro de ingresos totales suministrados y si no existiesen se ha decidido no imputarles por lo que no se generaría una predicción, los valores de visitantes del Caixaforum serán imputados con los percentiles 25, 50, y 75 (1419, 1934, 2739 visitantes diarios) de los valores históricos que tenemos registros generando así tres escenarios de predicción (pesimista, promedio, y optimista).

La siguiente tabla presenta las métricas de rendimiento obtenidas en Enero 2026:

Variable	n	MAE	RMSE	MAPE %	AbsError P95
Ingresos Totales (€)	29	259,29	329,28	14,25	588,93
Cafés Clásicos (uds.)	29	29,66	38,56	12,77	77,60
Desayunos, tostadas y panes (uds.)	29	10,97	14,41	18,56	26,00
Dulces y Repostería (uds.)	29	11,79	16,26	14,80	33,40

Tabla 3. *Métricas de evaluación de los modelos de producción Prophet, predicción de Enero 2026.*

De los 31 días del mes, se obtuvieron predicciones para 29 días los días 7 y 8 de enero carecen de predicción debido a que la variable de retardo de 14 días (invoices_lag_14) capturó el cierre del establecimiento durante dos días de diciembre, generando valores nulos que impidieron la generación de la predicción para esas fechas.

Los resultados muestran un rendimiento satisfactorio para los cuatro modelos (Tabla 3), con valores de MAPE comprendidos entre el 12,77% y el 18,56%. El modelo de Cafés Clásicos obtiene el mejor rendimiento relativo (MAPE 12,77%), lo que se explica por la mayor estabilidad y previsibilidad de esta categoría. El modelo de ingresos totales alcanza un MAPE del 14,25%, con un MAE de 259,29 €, lo que implica que la predicción se desvía en promedio aproximadamente 260 € del valor real en promedio diario durante el mes de enero.

El modelo de Desayunos, tostadas y panes presenta el MAPE más elevado (18,56%), lo que sugiere una mayor dificultad para predecir esta categoría. Este resultado puede atribuirse a la mayor sensibilidad de los Desayunos, tostadas y panes a factores no capturados por el modelo, como las condiciones meteorológicas de la mañana específica o la variabilidad en la oferta de productos frescos.

6.2. Resultados del Text Mining.

El análisis de text mining aplicado sobre las reseñas de Google de Café Madrid (2024–2025) clasificó la percepción de los clientes en ocho categorías, evaluadas mediante un índice compuesto (0–100) que combina en igual medida el volumen de menciones y las valoraciones (ratings) promedio (Figura 8). Es importante tener en cuenta que una puntuación (score) bajo no significa necesariamente que los clientes estén insatisfechos, sino que esa categoría tiene pocas menciones en las reseñas, por lo que ambos factores deben analizarse juntos.

Food (92/100), General (87/100), Coffee (83/100) y Service (82/100) son las categorías con mejor rendimiento: concentran el mayor número de menciones y mantienen valoraciones (ratings) por encima de 4.2 estrellas, lo que indica que estos atributos no solo satisfacen al cliente sino que son los que más aparecen en sus recomendaciones. Atmosphere destaca con la valoración (rating) más alta de todas las categorías (4.6), aunque con un volumen de menciones más bajo (953), lo que sugiere que quienes lo mencionan lo valoran muy bien pero no es el primer aspecto que los clientes comentan espontáneamente.

El caso más relevante es Price (47/100), que combina un volumen de menciones reducido con la única valoración media por debajo de 4.0 estrellas (3.6), convirtiéndose en el único atributo donde se identifica insatisfacción real. Features (42/100) y Location (64/100), en cambio, presentan valoraciones (ratings) aceptables, por lo que sus puntuaciones (scores) más bajos se explican principalmente por su escasa presencia en las reseñas y no por una valoración negativa de los clientes.

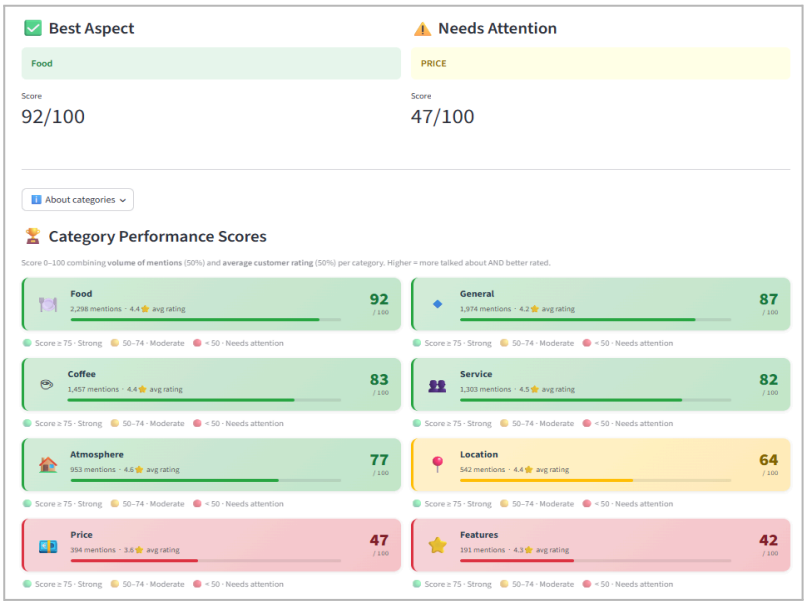

Figura 8. *Captura de pantalla de la APP Pythia. Módulo de Análisis de Reseñas.*

7. Despliegue Interfaz Streamlit[9].

Interfaz de Usuario y Despliegue de la Aplicación. Los resultados del análisis de reseñas y las predicciones de ventas se integran en una aplicación web desarrollada mediante Streamlit, un framework de Python orientado a la creación rápida de interfaces de datos interactivas. La elección de Streamlit como plataforma de despliegue responde a la necesidad de ofrecer al usuario final un acceso sencillo e intuitivo a las funcionalidades del sistema, sin que este requiera tener instalado Python ni ninguna dependencia adicional en su entorno local.

Para el desarrollo e implementación de la aplicación, el código fuente — estructurado de forma modular, con un archivo independiente por cada página de la interfaz — ha sido versionado y alojado en un repositorio de GitHub. Posteriormente, se ha establecido una integración continua entre dicho repositorio y la plataforma Streamlit Community Cloud, lo que permite el despliegue automático de la aplicación en la nube y garantiza que cualquier actualización del código en el repositorio se refleje de forma inmediata en la aplicación desplegada.

El modelo de predicción de ventas, una vez entrenado, ha sido serializado en formato Joblib y almacenado directamente en el repositorio de GitHub, desde donde la aplicación lo carga en tiempo de ejecución al momento en que el usuario activa el proceso de inferencia mediante el botón *"Predict"* (Figura 9).

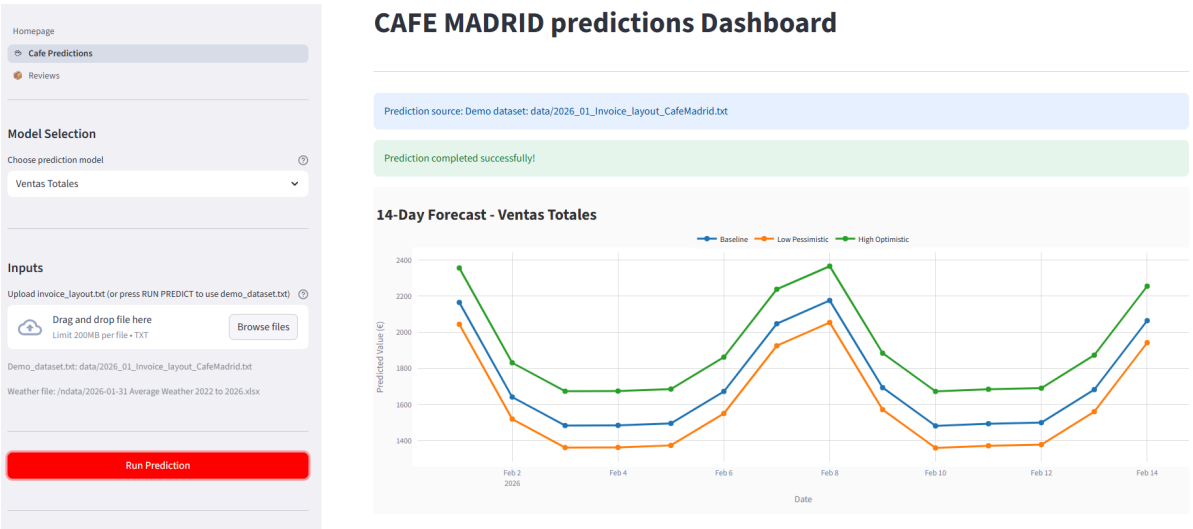

Figura 9. *Captura de pantalla de la APP Pythia. Módulo de predicción de Ingresos totales y ventas de unidades de producto.*

La app se compone de dos páginas principales:

[9] Se puede acceder la interfaz del usuario a través del enlace: https://pythia-bestcafeinmadrid.streamlit.app/

Módulo de predicción de Ingresos totales y ventas de unidades de producto[10]. Para llevar a cabo la predicción, el usuario debe proporcionar como entrada un archivo en formato .txt (información cinta) que contenga los registros de facturación de por lo menos 15 días. Una vez cargado el archivo .txt, la aplicación ejecuta un pipeline de procesamiento que comprende las siguientes etapas: transformación del .txt a JSON, y luego del JSON al formato .csv con toda la información, aplicación del mismo proceso de preprocesamiento de datos utilizado durante el entrenamiento del modelo, y generación de las predicciones por lo menos 15 días posteriores al período de entrada.

En cuanto a la visualización de resultados, la interfaz presenta al usuario tres escenarios de predicción diferenciados: un escenario base (*baseline*), un escenario pesimista y un escenario optimista (Figura 9). Asimismo, el usuario dispone de la opción de visualizar las predicciones de manera agregada o desglosada por unidades de venta de categoría de producto.

Módulo de Análisis de Reseñas[11]. La segunda sección de la aplicación está dedicada al análisis de reseñas extraídas de las plataformas Google Maps y TripAdvisor, tanto del establecimiento propio como de los competidores más próximos. Esta sección se organiza en dos subsecciones diferenciadas.

La primera, denominada *Coffee Shop Analysis*, se centra exclusivamente en las reseñas del propio local y ofrece dos capas de análisis: por un lado, la evolución histórica del sentimiento expresado por los clientes a lo largo del tiempo; por otro, la visualización de insights agrupados por categoría temática, permitiendo al usuario seleccionar tanto la categoría de interés como el tipo de sentimiento que desea explorar, clasificado en cuatro niveles: muy positivo, positivo, neutro y muy negativo.

La segunda subsección, denominada *Competitor Analysis*, aborda el análisis competitivo del entorno inmediato. En ella se presentan los insights extraídos de las reseñas con una valoración igual o superior a cuatro estrellas de los 12 competidores más cercanos al establecimiento. El usuario tiene la posibilidad de comparar de forma directa los insights del propio local con los de cada uno de los competidores, así como de realizar un análisis en profundidad (*deep dive*) sobre cada establecimiento de manera individual.

8. Conclusiones

El presente Trabajo Fin de Máster ha cumplido satisfactoriamente los cinco objetivos específicos planteados, demostrando la viabilidad de implementar un sistema de apoyo a la toma de decisiones para una microempresa hostelera mediante una arquitectura basada en herramientas de código abierto y soluciones tecnológicamente viables en entornos de pequeña escala.

Modelo de predicción de Ingresos Totales. Se cumplieron los objetivos 1 y 2: se construyeron cuatro modelos predictivos Prophet con horizonte de 14 días (ingresos totales,

[10] Vídeo con demostración de la interfaz Streamlit – Predicciones: 2026 02 18 Pythia Cafe Predictions Demo

[11] Vídeo con demostración de la interfaz Streamlit - Reseñas: 2026 02 18 Pythia reviews analysis Demo

y venta de unidades de tres categorías principales) y se cuantificó el impacto de factores externos.

En la fase de diseño Prophet demostró superioridad sobre alternativas: en predicción de ingresos alcanzó MAPE de 11,5% frente al 17,2% de XGBoost y 14,7% de Regresión Lineal. De los factores externos, el festivo de Pride Madrid es uno de los mayores, con un incremento esperado de hasta más del 100% del ingreso total promedio, otros festivos producen una variación de +/- 25%. El número de visitantes Caixaforum es el segundo factor externo más importante, con efecto de entre -20% a +40% de los ingresos, lo cual nos hace pensar que esta variable funciona más como un indicador indirecto de la afluencia de personas en el área cercana al Café Madrid. En cuanto al clima, los mayores efectos los tienen la temperatura promedio del día con un efecto en el ingreso total de +/- 6% de variación y los días muy fríos con hasta -3.5% del ingreso total. Los retardos en conteo de facturas pueden explicar hasta +/- 200 € en la predicción. Cabe mencionar, que la variable precipitación no fue significativa en el modelo, y se asume que su efecto está capturado en las componentes estacionales internas del modelo.

La validación en producción durante enero de 2026 confirmó rendimientos satisfactorios: con error promedio absoluto porcentual (MAPE) de 14.25 % para la predicción de ingresos diarios, y un MAPE con rango de 12.8-18.6 % en las predicciones de ventas de categorías de productos.

Modelo de text mining. Se cumplieron los objetivos 3 y 4, se procesaron 2.510 reseñas mediante un pipeline YAKE + NLTK + Sentence-BERT que extrajo 22.629 menciones consolidadas en 5.522 elementos normalizados (objetivo 3). La principal fortaleza identificada es el servicio al cliente: más de 1.170 comentarios positivos con valoraciones entre 4,5 y 4,8, y la frase "highly recommended" aparece más de 200 veces con nota casi perfecta. Como áreas de mejora, el uso de plásticos genera rechazo severo (rating 1,0), y se detectó una caída del rating promedio de 4,52 a 4,13 en el último semestre (-8,6%), señal de alerta que requiere investigación. El benchmarking competitivo (objetivo 4) se abordó con más de 5.000 reseñas de la zona. Técnicamente, YAKE demostró eficacia para extraer frases completas sin entrenamiento previo, y Sentence-BERT redujo los temas en un 37% sin pérdida de información.

Despliegue. Se cumplió el objetivo 5: interfaz Streamlit desplegada en producción, accesible sin conocimientos técnicos, con actualización quincenal automatizada de predicciones y análisis de reseñas.

Referencias Bibliográficas

[1] AEMET – Agencia Estatal de Meteorología (2025). Datos climatológicos históricos. https://www.aemet.es/

[2] Campos, R., Mangaravite, V., Pasquali, A., Jorge, A., Nunes, C. y Jatowt, A. (2020). YAKE! Keyword extraction from single documents using multiple local features. Information Sciences, 509, 257-289.

[3] Fundación la Caixa (2024). CaixaForum Madrid – Datos de visitantes. https://caixaforum.org/es/madrid

[4] Hyndman, R. J. y Athanasopoulos, G. (2021). Forecasting: Principles and Practice (3rd ed.). OTexts. https://otexts.com/fpp3/

[5] Liu, B. (2012). Sentiment Analysis and Opinion Mining. Synthesis Lectures on Human Language Technologies, Morgan & Claypool.

[6] Loria, S. (2020). TextBlob: Simplified Text Processing. https://textblob.readthedocs.io/

[7] Meta – Prophet Documentation (2024). https://facebook.github.io/prophet/

[8] Reimers, N. y Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. Proceedings of EMNLP-IJCNLP 2019.

[9] SerpAPI (2024). Google Maps Reviews API. https://serpapi.com/google-maps-reviews-api

[10] Streamlit Inc. (2024). Streamlit: The fastest way to build data apps. https://streamlit.io/

[11] Taylor, S. J. y Letham, B. (2018). Forecasting at Scale. The American Statistician, 72(1), 37-45. https://doi.org/10.1080/00031305.2017.1380080

ANEXOS

A.Códigos Python en formato html

A.1. Códigos del ETL

- 2026-02-04 — Input file single function_pipeline (V_1.0) Modelo de Predicción
- Scraping_Reviews_Competitor Modelo de Text Mining & NLP

A.2. Códigos del EDA

- 2026-01-19 — EDA Cleaning Decisions IA AB Series Temporales
- EDA - CustomerReviews_Analysis_V20260217 Text Mining
- Evolution_star_based_sentiment_vs_total_reviews Text Mining

A.3. Códigos de los Modelos de predicción de Ventas y Cantidades

Modelo de Revenue

- 2026-01-25 — Modelos TFM Ventas Prophet (V_1.14) Desarollo: entrenamiento 2022-2024, evaluación todo 2025
- 2026-01-31 — Modelos TFM Ventas Prophet (V_2.01) Producción: entrenamiento 2022-2025 + escenarios

Modelo de Cantidades de Cafés Clásicos

- 2026-01-25 — Modelos TFM Cafe_clasico Prophet (V_1.4) Desarollo: entrenamiento 2022-2024, evaluación todo 2025
- 2026-02-01 — Modelos TFM Cafe Clásicos Prophet (V_2.01) Producción: entrenamiento 2022-2025 + escenarios

Modelo de Cantidades de Dulces y Repostería

- 2026-01-25 — Modelos TFM DULCES_Y_REPOSTERIA Prophet (V_1.14) Desarollo: entrenamiento 2022-2024, evaluación todo 2025
- 2026-02-01 — Modelos TFM Dulces y repostería Prophet (V_2.01) Producción: entrenamiento 2022-2025 + escenarios

Modelo de Cantidades de Desayunos (Tostadas / Panes)

- 2026-01-30 — Modelos TFM DESAYUNOS_TOSTADAS_PANES Prophet (V_1.2) Desarollo: entrenamiento 2022-2024, evaluación todo 2025
- 2026-01-31 — Modelos TFM Desayunos Tos Pan Prophet (V_2.01) Producción: entrenamiento 2022-2025 + escenarios

Model Monitoring

Evaluación / seguimiento del rendimiento del modelo en producción.

- 2026-02-11 — Model Monitoring Evaluation (V_1.0)

A.4. Códigos del Text Mining y de la Análisis de Sentimiento

- ExtraccionInsightsCostumerReviews_v20260217
- InsightsCompetitors.html
- Mapa — Coffee Shops Madrid (2026-02-10)

A.5. Códigos del Interfaz del Usuario

- https://github.com/lucaiaco21/Pythia/ Interfaz del Usuario (UI)

B. Hiperparámetros óptimos seleccionados modelos Prophet.

Los cuatro modelos comparten una configuración base común de hiperparámetros, definida tras un proceso iterativo de experimentación:

Hiperparámetro	Ingresos Totales (Total_revenue)	Cafés Clásicos	Desayunos, tostadas y panes	Dulces y Repostería
mcmc_samples	300	300	300	300
seasonality_mode	multiplicative	multiplicative	multiplicative	multiplicative
yearly_seasonality	12	20	12	8
seasonality_prior_scale	5.0	5.0	5.0	2.5
changepoint_prior_scale	0.35	0.35	0.35	0.35
holidays_prior_scale	1.15	1.15	1.15	1.15
weekly_seasonality	True	True	True	True
daily_seasonality	False	False	False	False
Capping (y)	3.500 €	350 uds.	300 uds.	350 uds.

Anexo Tabla B1. Hiperparámetros para entrenamiento de modelos Prophet, un modelo por variable.

Cafés Clásicos: Alta complejidad estacional (yearly_seasonality=20) para capturar fluctuaciones intra-anuales pronunciadas.

Dulces y Repostería: Comportamiento más estable; se reduce la complejidad (yearly_seasonality=8) y se aumenta la regularización (prior_scale=2.5) para evitar el sobreajuste al ruido.

Revenue y Desayunos: Configuración equilibrada (yearly_seasonality=12)..

Inferencia MCMC (300 muestras): Se priorizó el uso de MCMC sobre MAP para obtener distribuciones de probabilidad completas e intervalos de confianza que reflejen la incertidumbre real, asumiendo un mayor coste computacional compensado por la baja frecuencia de reentrenamiento (quincenal).

Flexibilidad y Estacionalidad: Se estableció changepoint_prior_scale=0.35 para capturar tendencias de crecimiento sin overfitting, y un modo multiplicativo debido a que las oscilaciones de la serie escalan proporcionalmente con su nivel.

Festivos (prior_scale=1.15): Ajuste optimizado tras experimentación para evitar que el efecto de los festivos fuera excesivo en fechas con poco histórico.

Regresores Externos: Se integraron variables climáticas y de afluencia (CaixaForum) en modo multiplicativo (impacto proporcional a los Ingresos Totales), excepto el retardo de facturación (invoices_lag_14), configurado como aditivo al representar una señal de actividad base.

C. Conjuntos de datos y tablas más relevantes

Conjunto de datos

Predicción de series temporales	2026-01-16 Cafe Madrid Invoices 2019 to 2025 in table format.xlsx - Obtenido mediante la conversión a JSON del archivo de salida del sistema informático de Cafe_Madrid_UCM, con diseño de facturas en formato de texto, y por último conversión a tabla.
	2026-01-24 daily_ml_df_wea_cal_and_cxf manually filled na and holidays.xlsx - Dataset con la ventana temporal final seleccionada para el entrenamiento, comprendiendo desde el 1 de enero de 2022 hasta el 31 de diciembre de 2025.
	2026-01-06 clima historico 2022 to 2025.csv Conjunto de datos de la plataforma oficial AEMET con la fecha 1 de enero del 2022 - 31 de diciembre 2025
	holidays_2022_2026.xlsx - Lista de días festivos oficiales de la ciudad de Madrid (ESP), de enero de 2022 a diciembre de 2026.
	2026-01-31 Average Weather 2022 to 2026.xlsx - Conjunto de valores promedio 2022 a 2025 de temperatura y precipitaciones.

Text Mining y Procesamiento de Lenguaje Natural	Reviews En - Reseñas sobre Cafe_Madrid_UCM en Google, en el periodo comprendido entre septiembre de 2014 y noviembre de 2025, proporcionadas por el propietario del establecimiento, y traducidas al inglés.
	EnglishReviews.csv - Resenas de los principales competidores de el coffee shop extraido con webscraping y traducidas en inglés.

Tablas

Predicción de series temporales	2026-01-05 unique_products_categories.xlsx - 322 productos únicos identificados en el catálogo se clasificaron manualmente en 17 categorías de producto.
	2026_01_Invoice_layout_CafeMadrid_anomizado.txt - *Layout* de facturas (anomizadas) de Cafe_Madrid_UCM de enero de 2026, utilizado como base de demostración para la Predicción en la interfaz de Streamlit.

Text Mining y Procesamiento de Lenguaje Natural	insights_cafemadridUCM.csv
	per_restaurant_insights.csv
	global_insights.csv
	restaurant_summary.csv
	common_insights_all_restaurants.csv
	El_CafeMadridInsights_clean.csv
	final_top_10_insights.csv

	top_10_per_restaurant.csv
	top_insights_by_category.csv

D. Documentos

- Aprobación de la anonimización del nombre del establecimiento comercial NDA_TFM_UCM_CAIXA_FORUM-CR_Firmado.pdf

E. Videos

- Vídeo con demostración de la interfaz Streamlit:
    - 2026 02 18 Pythia Cafe Predictions Demo
    - 2026 02 18 Pythia reviews analysis Demo
- Vídeo general sobre la aplicación Pythia - Pythia_pitch in Youtube